Cómputo Paralelo

y en la Nube

Proyecto

Apertura

K-means con OpenMP

K-means

Paso 0. Datos

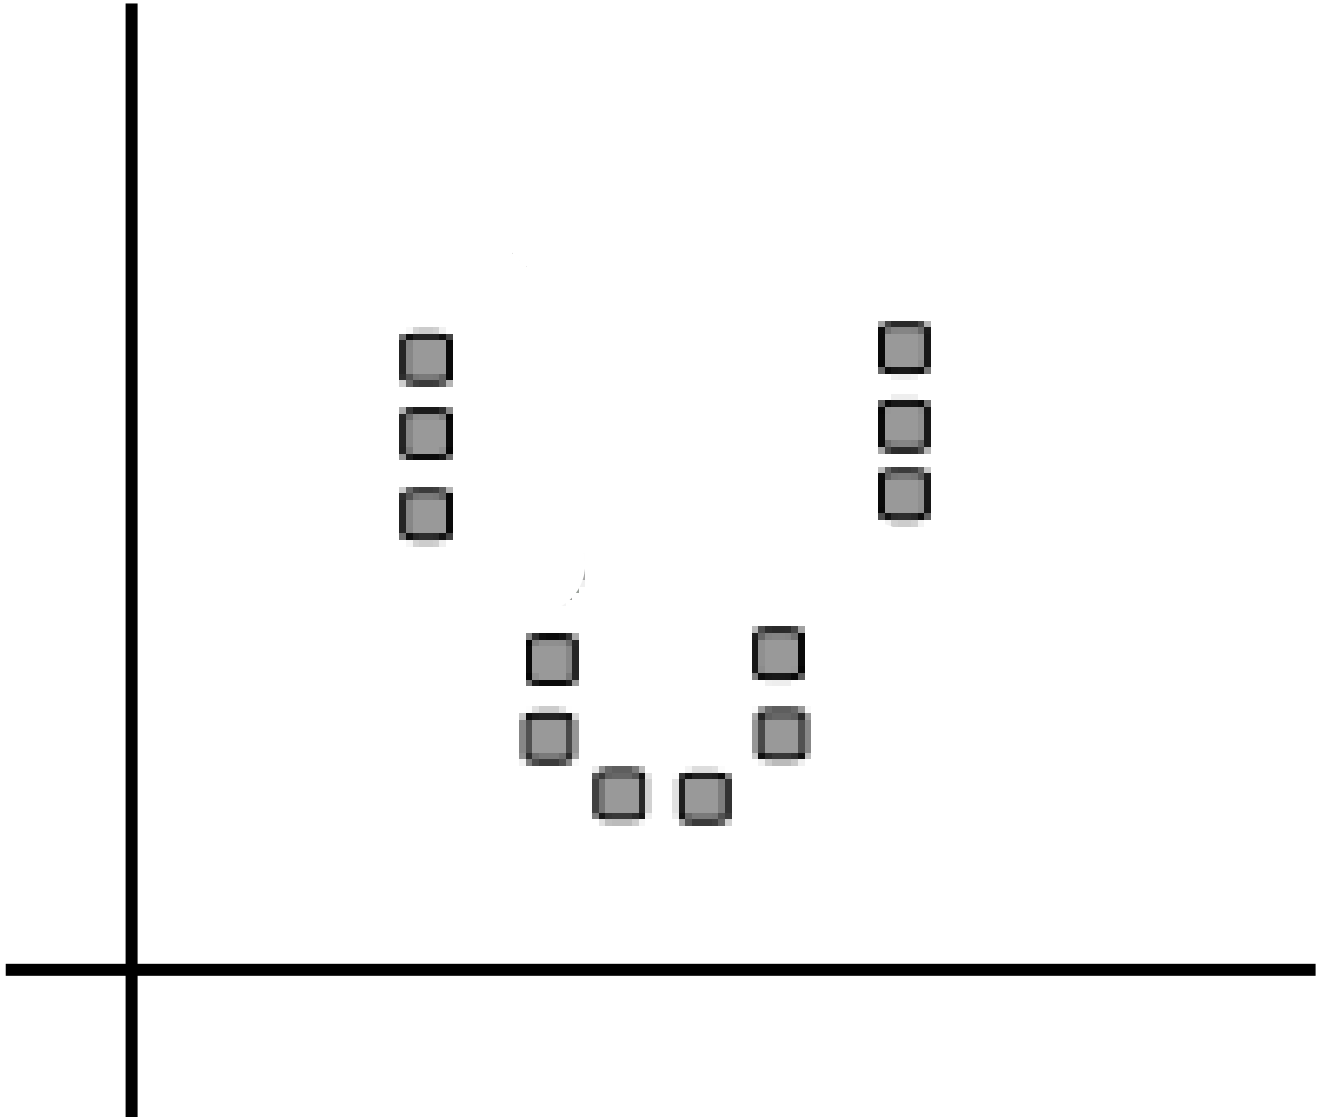

Imágenes extraídas de Wikipedia

https://es.wikipedia.org/wiki/K-medias

K-means

Paso 1. ***Crear k centroides y distribuirlos aleatoriamente sobre los datos***

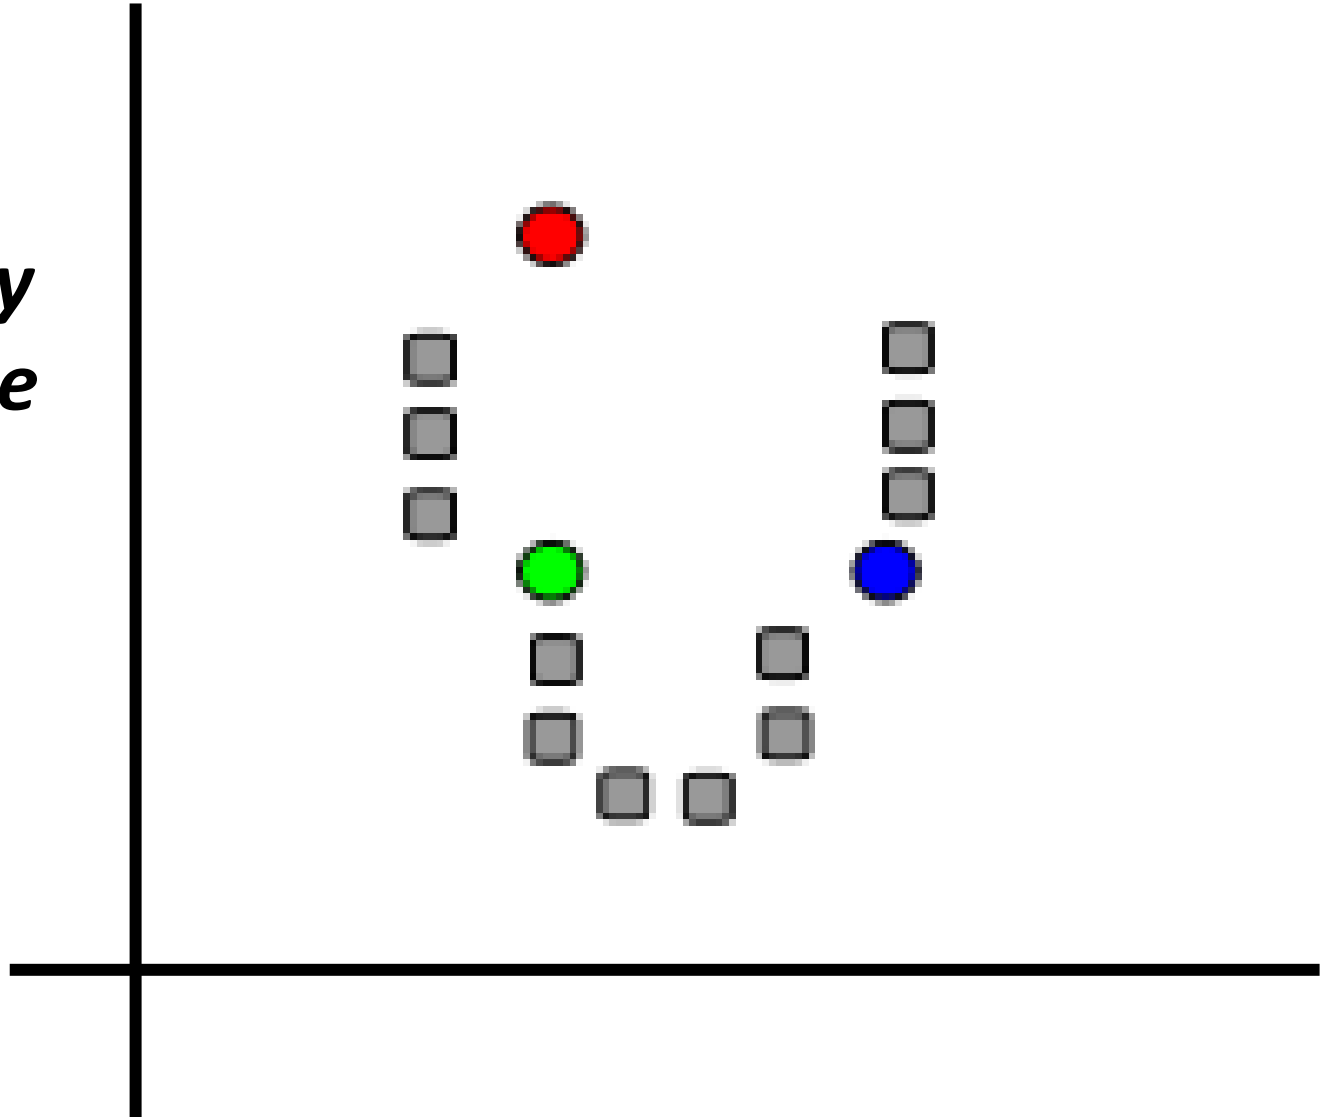

Imágenes extraídas de Wikipedia

https://es.wikipedia.org/wiki/K-medias

K-means

Paso 2. ***Asignar los puntos al centroide más cercano***

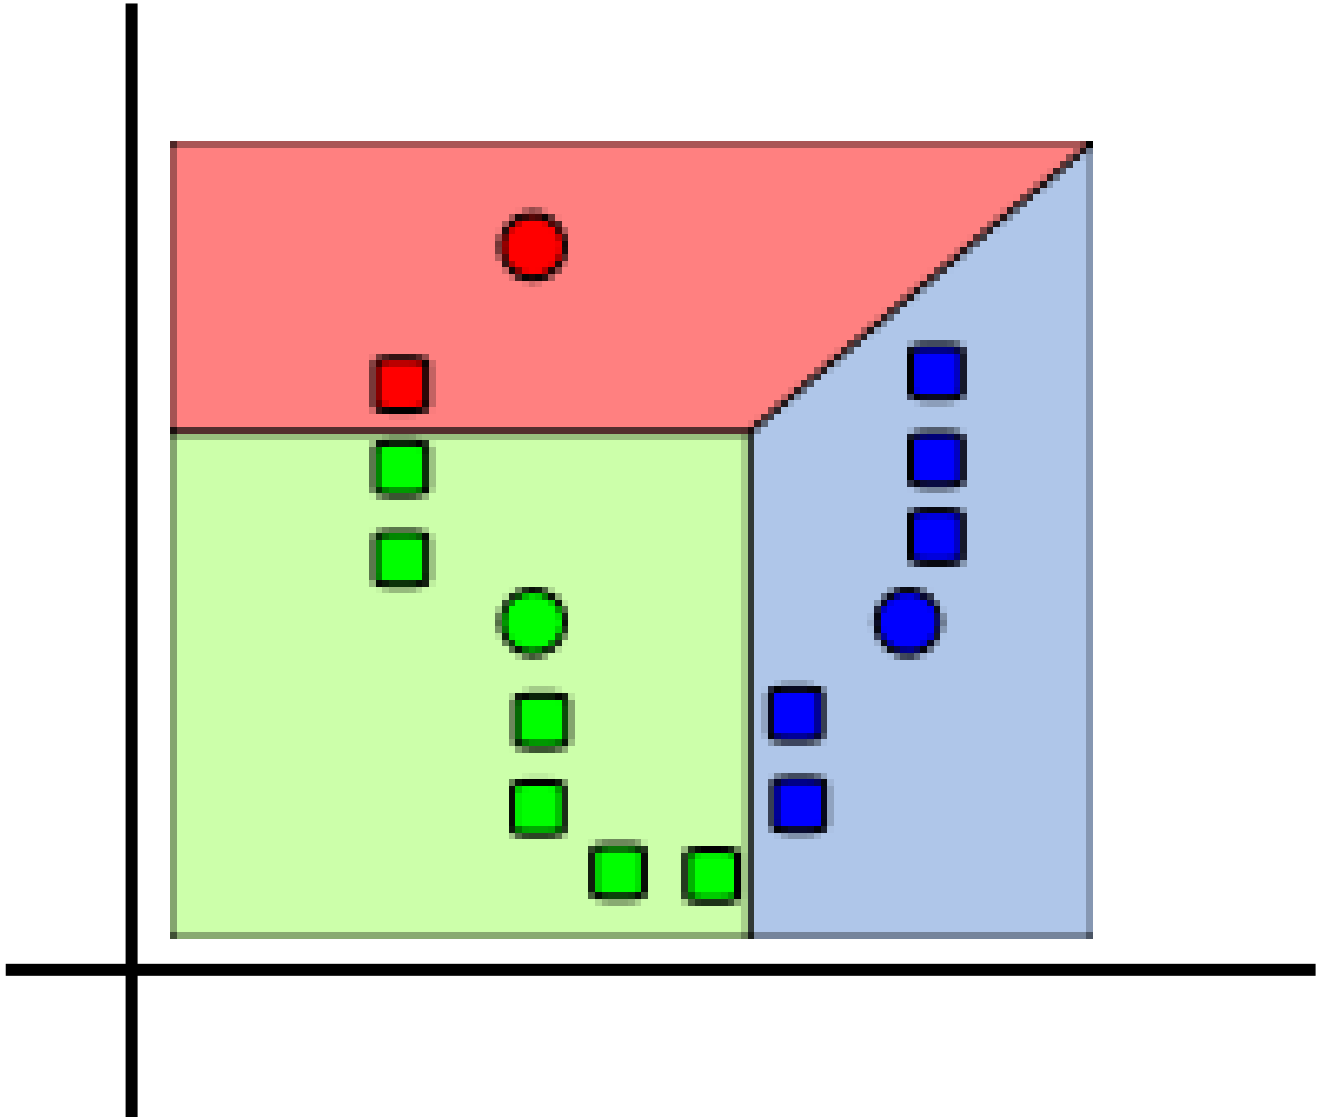

Imágenes extraídas de Wikipedia

https://es.wikipedia.org/wiki/K-medias

K-means

***Paso 3*. Actualizar la posición de los centroides**

***Centroide X* = Promedio de todas las posiciones X de sus puntos**

***Centroide Y* = Promedio de todas las posiciones Y de sus puntos**

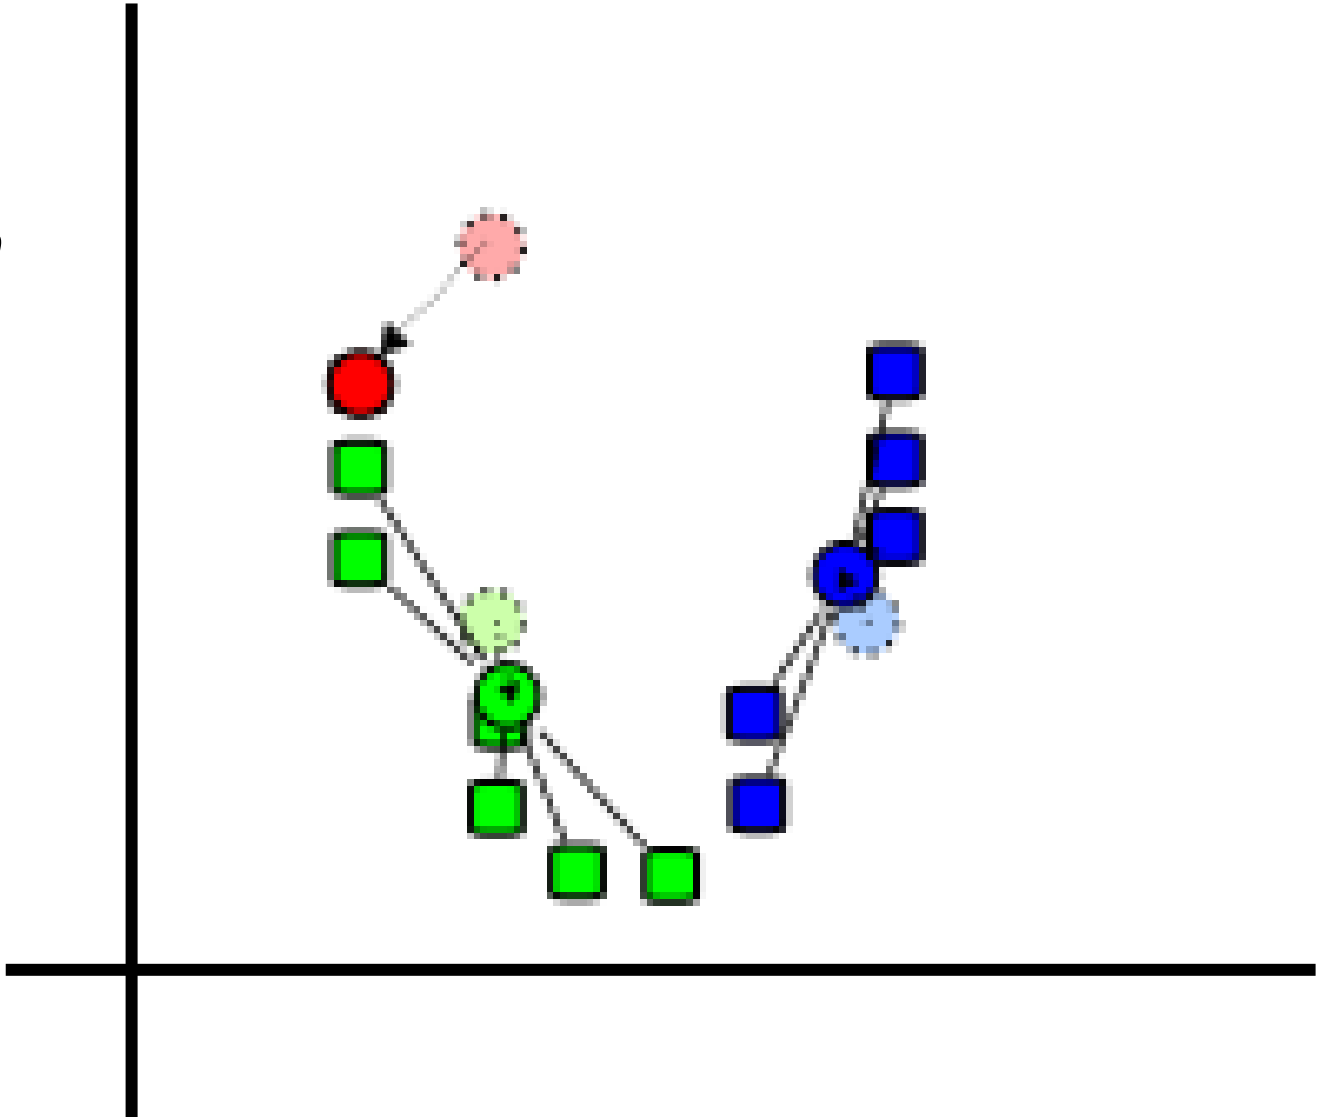

Imágenes extraídas de Wikipedia

https://es.wikipedia.org/wiki/K-medias

K-means

Repetir pasos 2 y 3 hasta que ningún punto cambie de cluster.

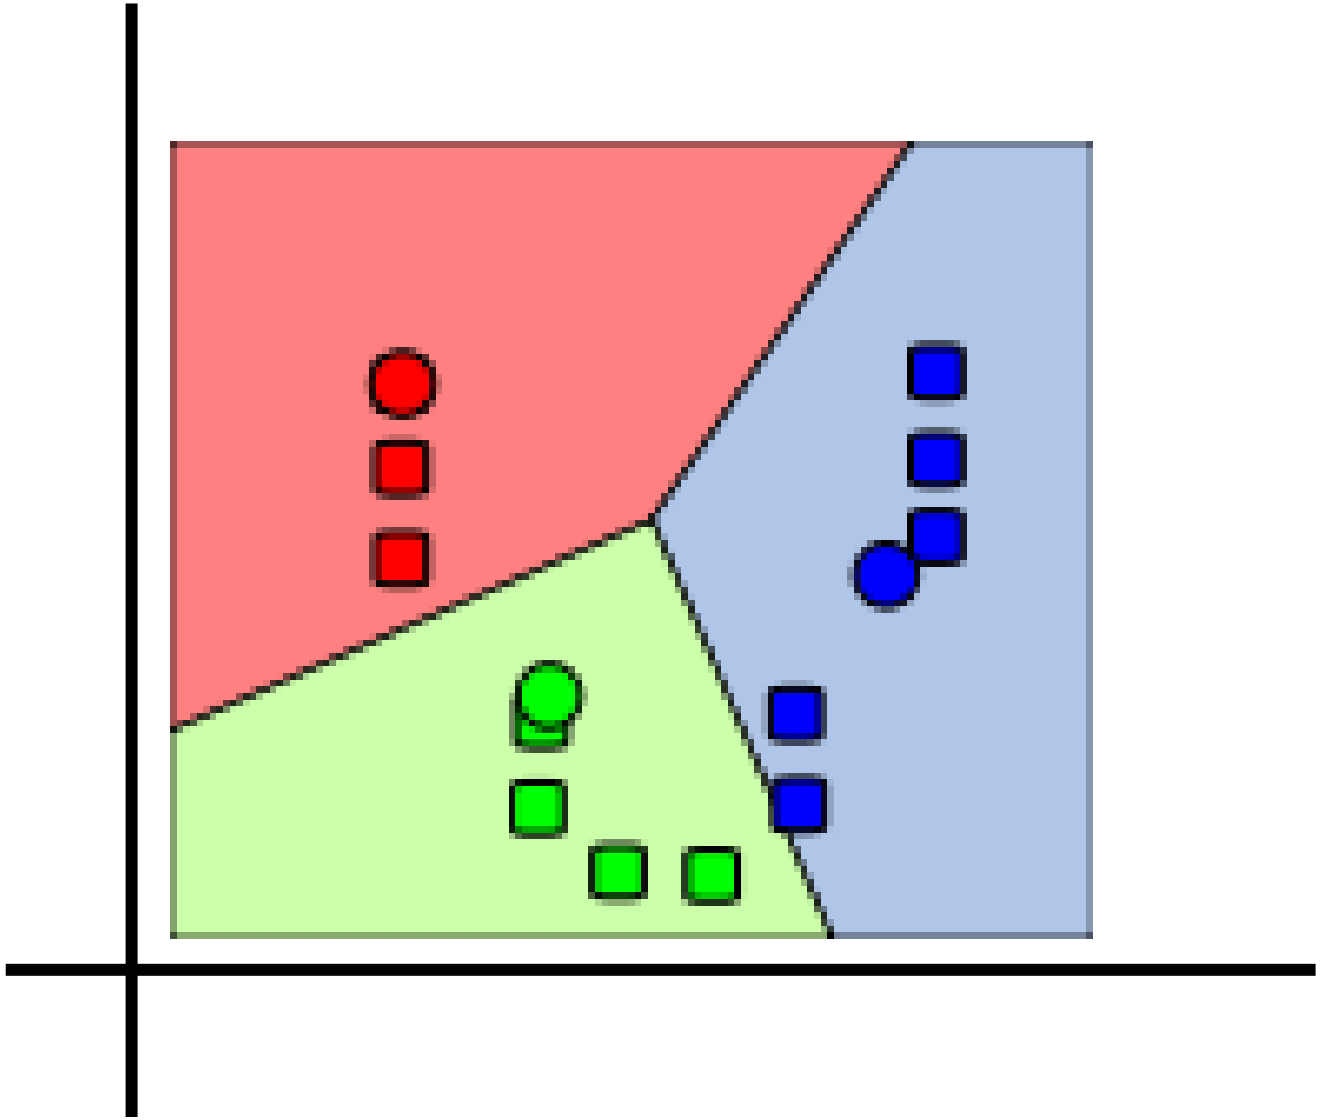

Imágenes extraídas de Wikipedia

https://es.wikipedia.org/wiki/K-medias

K-means – distancia

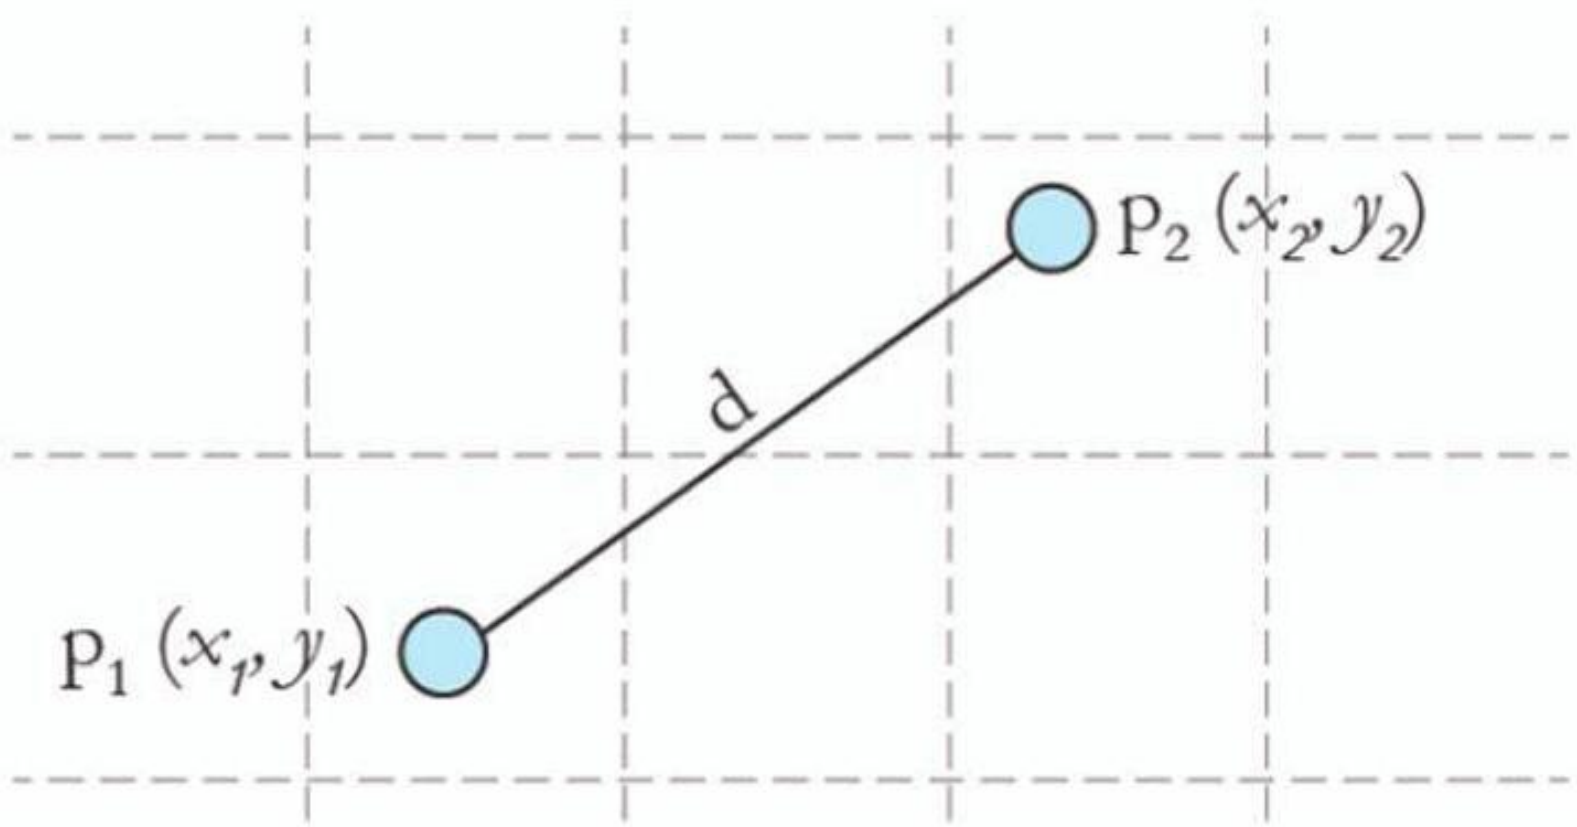

$$\text{Euclidean distance (d)} = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

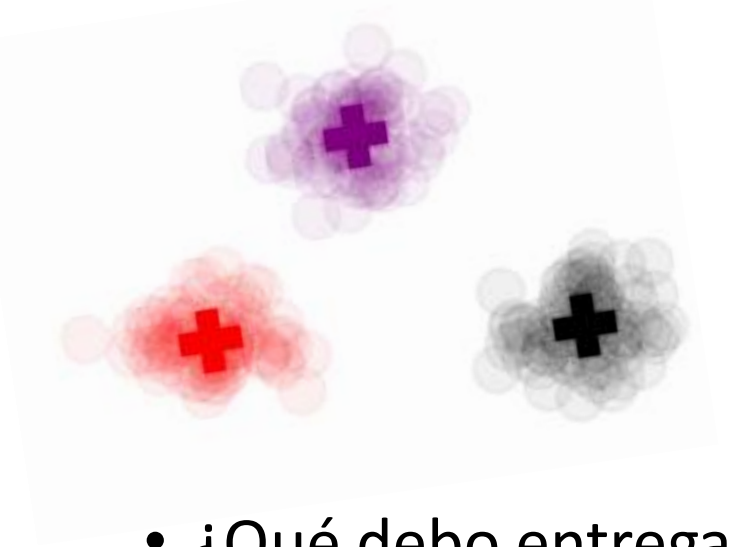

K-means Paralelo

- ¿Qué debo entregar?
  - Todo el código fuente
    - Versión serial.
    - Versión paralelizada.
  - Escrito con una descripción del código y de la estrategia de paralelización
  - Escrito con una descripción de la evaluación experimental de desempeño:
    - Explicación detallada de la definición del experimento.
    - Descripción del equipo donde se ejecutaron los experimentos en términos de hardware y software.
    - Interpretación y análisis de resultados.
    - Incluir gráficas
    - Archivo con los datos de los experimentos

Experimento para evaluar Rendimiento

Parametrizar el programa

- 2 dimensiones (x, y) y 3 dimensiones (x, y, z)
- Número de puntos
  {100000, 200000, 300000, 400000, 600000, 800000, 1000000}
- Número de hilos
  {1, (número de cores virtuales)/2, número de cores virtuales, número de cores virtuales*2}
- En búsqueda de un speedup, es posible explorar más o menos hilos.

- Promediar diez iteraciones para cada configuración
- ***Entrada del programa: PUNTOS ALEATORIOS. El programa debe recibir (como entrada) un archivo csv (ya sea en dos o tres dimensiones) que se puede generar usando la libreta synthetic_clusters.ipynb que se encuentra en el respositorio del curso.***
- ***Salida del programa: CLUSTERS. El programa debe generar (como resultado) un archivo csv que se pueda visualizar usando python.***
- ***Comparar contra version serial***
- ***Obtener gráfica de Speed Ups***

Criterios de evaluación

- Equipo de 1 o 2 personas.
- Peso total del proyecto: 2 puntos de su calificación final.
- Ejecución del proyecto con todos los requerimientos indicados en su descripción (1.2 puntos)
- Calidad y presentación de los documentos de descripción de código y evaluación experimental de desempeño (0.8 puntos)
- Fecha de entrega de código y documentación: **Martes 24 de Marzo de 2026** en clase.

- NOTA 1: La versión paralela debe ser más rápida que la versión serial, al menos debe presentar un speed up de 1.5.
- NOTA 2: Si es una sola persona puede 1) hacer la mitad de los experimentos, 2) no entregar el escrito con la descripción del código y de la estrategia de paralelización (aunque SÍ tiene que entregar el escrito con la descripción de la evaluación experimental de desempeño).
- NOTA 3: 20% menos por cada día natural de retraso.
- NOTA 4: Si se entrega después de la hora de entrega, en automático aplica un día menos.